

איתי הפילוני, ת"ז 207799446

תו משעלי, ת"ז 209177187

נוי סלע, ת"ז 318803137

מבוא:

רישום פעילות חשמלית מהמוח (EEG) הוא כלי נפוץ ולא פולשני למדידת פעילות עצבית בזמן אמת, באמצעות אלקטרודות המוצמדות לקרקפת הנבדק.

אחד המרכיבים הבולטים באותות EEG הוא קצב האלפא – פעילות מחזורית בתדר של כ-8–12 הרץ, אשר מופיעה באופן מובהק במצב מנוחה ובעיקר כאשר עיני הנבדק עצומות. עם זאת, מיקום השיא של פעילות האלפא (כלומר, התדר שבו מתקבל הערך המרבי של צפיפות ההספק) משתנה בין נבדקים, ונקרא IAF – Individual Alpha Frequency. תדר זה נחשב למדד נוירופיזיולוגי אישי שיכול להעיד על תפקוד קוגניטיבי, רמת ערנות ואף על מצבים נוירולוגיים מסוימים.

צפיפות ההספק (Power Spectral Density – PSD) מתארת כמה אנרגיה (או עוצמה) של האות מרוכזת בכל תדר. זוהי מדידה של תרומת כל תדר לעוצמה הכוללת של האות, והיא מאפשרת לנתח אילו תדרים פעילים יותר – למשל, האם יש פעילות בולטת בתדר האלפא לעומת תדרים אחרים.

מטרת תרגיל זה היא לאתר את תדר ה-IAF של שלושה נבדקים, באמצעות ניתוח ספקטרלי של אותות EEG שהוקלטו כאשר הנבדקים התבקשו להיות עם עיניים פקוחות (EO) ועם עיניים עצומות (EC).

לצורך כך חושבה צפיפות ההספק (PSD) של אות ה-EEG שנמדד מהאלקטרודה Pz, תוך שימוש בשתי שיטות חישוב: התמרת פורייה מהירה (FFT), ושיטת Welch, המשלבת חלונות חופפים לצמצום רעש.

בנוסף, בוצעה נרמול של ערכי ההספק, כדי לאפשר השוואה מדויקת בין השיטות.

שיטות:

הניתוח בוצע על נתוני EEG של שלושה נבדקים, שכללו מדידות במצב עיניים פתוחות (EO) ועיניים עצומות (EC). קבצי הנתונים היו בפורמט EDF, כאשר כל קובץ מכיל מטריצה בה שורה מייצגת ערוץ EEG ועמודה מייצגת נקודת זמן. הניתוח התמקד באלקטרודה מספר 19 (Pz), על פי הוראות התרגיל.

קריאת הקבצים בוצעה באמצעות שימוש בפונקציה edfread, אשר סופקה בקובץ עזר באתר הקורס. פונקציה זו קוראת את הנתונים ואת הסיגנלים שנרשמו מתוך קובץ ה-EDF, ומחזירה את ערכי הסיגנל לאחר המרה מייצוג דיגיטלי לערכים פיזיקליים.

```

def load_edf_channel19(edf_path): 2 usages
    _data = edfread(edf_path)
    return data[elecNum]

# Process each subject's folder
subject_data = {}
for subFolder in sorted(os.listdir(file_path)):
    subFolderPath = os.path.join(file_path, subFolder)
    ## 1. Data handling
    subject_num_match = re.search(pattern: r"S(\d+)", subFolder)
    if not subject_num_match: ...

    subject_num = int(subject_num_match.group(1))
    subject_data[subject_num] = {}

    if not os.path.isdir(subFolderPath):
        continue # skip if not a directory

    for file in os.listdir(subFolderPath):
        full_path = ""
        if file.endswith(".edf"):
            full_path = os.path.join(subFolderPath, file)
            if "EO" in file:
                subject_data[subject_num]['EO'] = load_edf_channel19(full_path)
            elif "EC" in file:
                subject_data[subject_num]['EC'] = load_edf_channel19(full_path)

```

בנוסף, בוצע חישוב של ספקטרום צפיפות ההספק (Power Spectrum) לכל אחד מהמצבים (EO ו-EC) עבור כל נבדק, בשתי שיטות שונות:

1. FFT - הספקטרום חושב באמצעות הפונקציה `compute_fft_power`, שהתבססה על הספרייה `numpy.fft`.
2. Welch - נעשה שימוש בפונקציה `compute_welch_power`, שהתבססה על הפונקציה `scipy.signal.welch`. פרמטרי השימוש היו: `welch(signal, fs=256, nperseg=512, noverlap=256, window='hamming')`.

תוצאות חישוב צפיפות ההספק נורמלו באמצעות חלוקה בכמות הדגימות X קצב הדגימה, ע"מ לאפשר השוואה בין השיטות.

```
def compute_fft_power(signal, fs): 4 usages
    N = len(signal)
    fft_vals = fft(signal)
    freqs = np.fft.fftfreq(N, d=1 / fs)

    # Take one-sided spectrum
    one_sided = freqs > 0
    power = (np.abs(fft_vals) ** 2) / (fs * N) # normalization
    return freqs[one_sided], power[one_sided]
```

```
def compute_welch_power(signal, fs): 4 usages
    freqs, psd = welch(signal, fs=fs, nperseg=512, noverlap=256, window='hamming', scaling='density')
    return freqs, psd
```

שתי השיטות הופעלו על כל אחד מהמצבים (EO ו-EC), ותוצאת צפיפות ההספק הוצגה בתרשים אחד עבור כל נבדק, בטווח התדרים 4–14 Hz.

```
def plot_welch_power_spectra(subject_id, ec_data, eo_data): 1 usage
    f_ec, p_ec = compute_welch_power(ec_data, fs)
    f_eo, p_eo = compute_welch_power(eo_data, fs)
    mask = (f_ec >= alpha_range[0]) & (f_ec <= alpha_range[1])
    plt.figure()
    plt.plot(*args: f_ec[mask], p_ec[mask], label='EC')
    plt.plot(*args: f_eo[mask], p_eo[mask], label='EO')
    plt.title(f'Subject {subject_id} - Welch Power Spectrum')
    plt.xlabel('Frequency (Hz)')
    plt.ylabel('Power [AU]')
    plt.legend()
    plt.grid()
    plt.tight_layout()
    plt.show()
```

```
def plot_fft_power_spectra(subject_id, ec_data, eo_data): 1 usage
    f_ec, p_ec = compute_fft_power(ec_data, fs)
    f_eo, p_eo = compute_fft_power(eo_data, fs)
    mask = (f_ec >= alpha_range[0]) & (f_ec <= alpha_range[1])
    plt.figure()
    plt.plot(*args: f_ec[mask], p_ec[mask], label='EC')
    plt.plot(*args: f_eo[mask], p_eo[mask], label='EO')
    plt.title(f'Subject {subject_id} - FFT Power Spectrum')
    plt.xlabel('Frequency (Hz)')
    plt.ylabel('Power [AU]')
    plt.legend()
    plt.grid()
    plt.tight_layout()
    plt.show()
```

לאחר חישוב הספקטרום, חושב ההפרש בין EC ל-EO עבור כל תדר. תדר ה-IAF הוגדר כתדר בו ההפרש הזה היה מקסימלי:

```
def find_iaf(freqs, power_ec, power_eo, alpha_range=(6, 14)): 2 usages
    diff = power_ec - power_eo
    mask = (freqs >= alpha_range[0]) & (freqs <= alpha_range[1])
    alpha_freqs = freqs[mask]
    alpha_diff = diff[mask]
    iaf_index = np.argmax(alpha_diff)
    iaf_freq = alpha_freqs[iaf_index]
    return iaf_freq, alpha_freqs, alpha_diff
```

התוצאות הוצגו באמצעות פונקציות ה-plotting הבאות:

1. עבור שיטת Welch -

```
def plot_welch_difference_spectrum(subject_id, ec_data, eo_data): 1 usage
    f_ec, p_ec = compute_welch_power(ec_data, fs)
    f_eo, p_eo = compute_welch_power(eo_data, fs)

    iaf_freq, alpha_freqs, alpha_diff = find_iaf(f_ec, p_ec, p_eo, alpha_range)
    plt.figure()
    plt.plot(*args: alpha_freqs, alpha_diff, label='EC - EO')
    plt.axvline(x=iaf_freq, color='r', linestyle='--', label=f'IAF = {iaf_freq:.2f} Hz')
    plt.title(f'Subject {subject_id} - Welch Difference Spectrum')
    plt.xlabel('Frequency (Hz)')
    plt.ylabel('Power Difference [AU]')
    plt.legend()
    plt.grid()
    plt.tight_layout()
    plt.show()
```

2. עבור שיטת FFT -

```
def plot_fft_difference_spectrum(subject_id, ec_data, eo_data): 1 usage
    f_ec, p_ec = compute_fft_power(ec_data, fs)
    f_eo, p_eo = compute_fft_power(eo_data, fs)

    iaf_freq, alpha_freqs, alpha_diff = find_iaf(f_ec, p_ec, p_eo, alpha_range)
    plt.figure()
    plt.plot(*args: alpha_freqs, alpha_diff, label='EC - E0')
    plt.axvline(x=iaf_freq, color='r', linestyle='--', label=f'IAF = {iaf_freq:.2f} Hz')
    plt.title(f'Subject {subject_id} - FFT Difference Spectrum')
    plt.xlabel('Frequency (Hz)')
    plt.ylabel('Power Difference [AU]')
    plt.legend()
    plt.grid()
    plt.tight_layout()
    plt.show()
```

תוצאות:

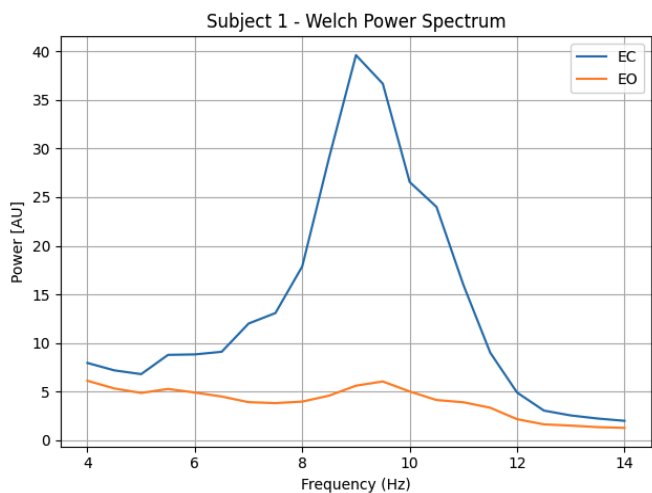


Figure 2 - השוואת צפיפות ההספק (PSD) בין עיניים עצומות (EC) לפתוחות (EO) בשיטת Welch בטווח תדרי אלפא בנבדק 1.




Figure 1 - השוואת צפיפות ההספק (PSD) בין עיניים עצומות (EC) לפתוחות (EO) בשיטת FFT בטווח תדרי אלפא בנבדק 1.

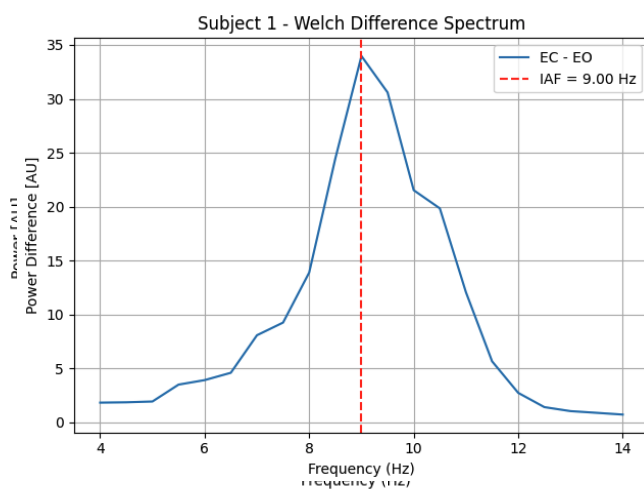


Figure 4 - הפרש בצפיפות ההספק בין EC ל-EO לפי Welch, עם זיהוי תדר ה-IAF המשקף את שיא פעילות האלפא בנבדק 1.

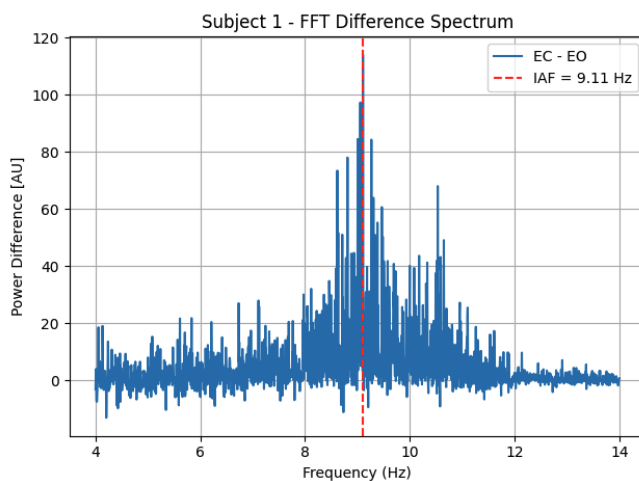


Figure 3 - הפרש בצפיפות ההספק בין EC ל-EO לפי FFT, עם זיהוי תדר ה-IAF המשקף את שיא פעילות האלפא בנבדק 1.

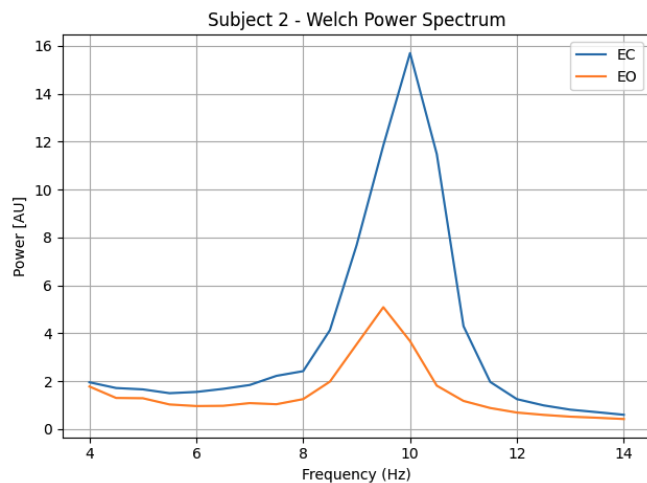


Figure 6 - השוואת צפיפות ההספק (PSD) בין עיניים עצומות (EC) לפתוחות (EO) בשיטת Welch בטווח תדרי אלפא בנבדק 2.

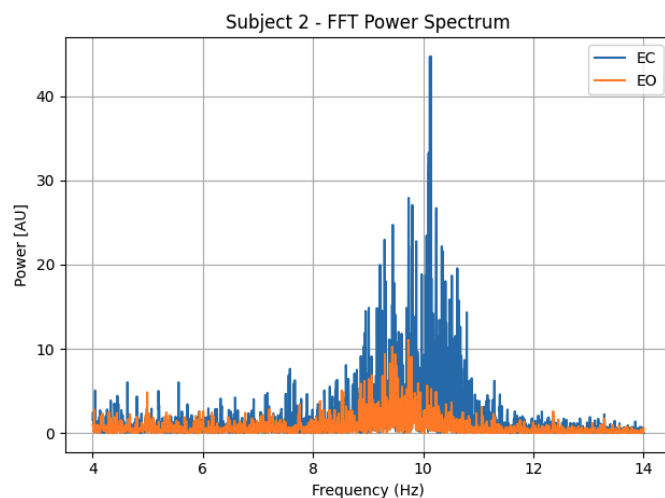


Figure 5 - השוואת צפיפות ההספק (PSD) בין עיניים עצומות (EC) לפתוחות (EO) בשיטת FFT בטווח תדרי אלפא בנבדק 2.

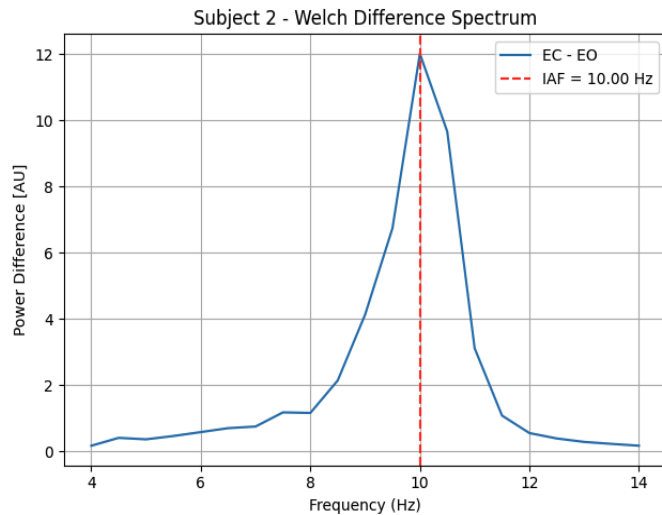


Figure 8 - הפרש בצפיפות ההספק בין EC ל-EO לפי Welch, עם זיהוי תדר ה-IAF המשקף את שיא פעילות האלפא בנבדק 2.




Figure 7 - הפרש בצפיפות ההספק בין EC ל-EO לפי FFT, עם זיהוי תדר ה-IAF המשקף את שיא פעילות האלפא בנבדק 2.

Subject 3 - FFT Power Spectrum




Figure 10 - השוואת צפיפות ההספק (PSD) בין עיניים עצומות (EC) לפתוחות (EO) בשיטת Welch בטווח תדרי אלפא בנבדק 3.

Subject 3 - Welch Power Spectrum




Figure 9 - השוואת צפיפות ההספק (PSD) בין עיניים עצומות (EC) לפתוחות (EO) בשיטת FFT בטווח תדרי אלפא בנבדק 3.

Subject 3 - Welch Difference Spectrum




Figure 12 - הפרש בצפיפות ההספק בין EC ל-EO לפי Welch, עם זיהוי תדר ה-IAF המשקף את שיא פעילות האלפא בנבדק 3.

Subject 3 - FFT Difference Spectrum




Figure 11 - הפרש בצפיפות ההספק בין EC ל-EO לפי FFT, עם זיהוי תדר ה-IAF המשקף את שיא פעילות האלפא בנבדק 3.

דיון:

מטרתו העיקרית של תרגיל זה הייתה לזהות את תדר ה-IAF (Individual Alpha Frequency) של כל נבדק, על בסיס ניתוח ספקטרלי של אותות EEG שהוקלטו במצבים של עיניים עצומות (EC) ועיניים פקוחות (EO). הניתוח בוצע בשתי שיטות נפוצות: FFT (התמרת פורייה מהירה) ו-Welch (הערכת צפיפות הספק עם חלונות חופפים), תוך נרמול של הספקטרום כדי לאפשר השוואה ישירה בין השיטות. בכל שלושת הנבדקים נצפתה עלייה ניכרת בצפיפות ההספק בתחום תדרי האלפא בזמן EC לעומת EO, בהתאם לממצאים הידועים בספרות, לפיהם פעילות אלפא בולטת במצב מנוחה עם עיניים עצומות ונחלשת באופן מיידי בעת פתיחת העיניים. תדר ה-IAF הוגדר כתדר שבו מתקבל ההפרש המרבי בין צפיפות ההספק במצב EC לעומת EO, ונמצא בטווח של כ-8.5 עד 11 הרץ, בהתאם לנבדק. ממצאים אלה תואמים את הספרות, המצביעה על כך שתדר האלפא משתנה בין פרטים ומהווה מדד אישי שעשוי לשקף תפקודים קוגניטיביים, רמת ערנות ואף מצבים קליניים. שתי שיטות הניתוח הניבו תוצאות דומות מבחינת מיקום תדר ה-IAF, אך נבדלו במאפייני הספקטרום: שיטת FFT סיפקה ספקטרום מחוספס יחסית אך בעל רזולוציה תדרית גבוהה, בעוד ששיטת Welch הפיקה ספקטרום חלק ומדויק יותר בזכות ממוצע על פני חלונות, שאפשר הפחתת רעש והבלטת שיאי הספק. נרמול ההספק אפשר השוואה ישירה בין השיטות, והראה כי למרות הבדלים ברמת החלקות, המסקנות העיקריות נשמרות בשתייהן.